

GSM Promotion Experimentation

TÀI LIỆU KỸ THUẬT - BẢN CUỐI

Sandbox mô phỏng thực nghiệm khuyến mãi và đánh giá chính sách

Phạm vi bằng chứng (Evidence Boundary). Dự án này là một sandbox mô phỏng cho bài toán experimentation. Hệ thống kết hợp dữ liệu mobility công khai/tham chiếu, dữ liệu causal tổng hợp, logic randomized experiment, uplift modeling, đánh giá policy theo business economics và giao diện hỗ trợ ra quyết định bằng Streamlit. Các kết quả trong môi trường synthetic chứng minh cách workflow vận hành và tính nhất quán nội bộ; chúng **không phải** ước lượng về phản ứng thực tế của khách hàng GSM và **không chứng minh** hệ thống đã sẵn sàng production nếu chưa được kiểm chứng bằng experiment trên dữ liệu GSM thực.

Mục lục / Cấu trúc tài liệu

Phần	Nội dung	Mục đích
1	Tóm tắt điều hành	Hệ thống làm gì, đã triển khai gì và có thể kết luận đến đâu
2	Phạm vi, Evidence Boundary và Source of Truth	Xác định cách diễn giải hợp lệ và xử lý mâu thuẫn với tài liệu tuần cũ
3	Bài toán nghiệp vụ và kỹ thuật	Định nghĩa bài toán phân bổ promotion và mục tiêu kỹ thuật
4	Kiến trúc hệ thống hiện tại	Mô tả implementation end-to-end từ data đến dashboard
5	Nền tảng dữ liệu và hiệu chỉnh	Giải thích dữ liệu tham chiếu và synthetic dataset hiện tại
6	Quy trình sinh dữ liệu causal tổng hợp	Định nghĩa Y0, Y1, CATE, treatment assignment và synthetic ground truth
7	Experimentation và kiểm định thống kê	A/A, SRM, balance, A/B, effect estimation và Monte Carlo validation
8	Phân khúc hành vi	Mô tả persona layer hiện tại và vai trò của segmentation
9	Uplift / CATE Modeling	Tài liệu hóa R-Learner-style implementation và diagnostics
10	Unit Economics và Policy Optimization	Định nghĩa Expected Value và policy comparison engine
11	Đánh giá và kiểm tra độ bền vững	Tổng hợp model, policy, calibration, Qini và stress-test evidence
12	Dashboard và lớp hỗ trợ ra quyết định	Mô tả workflow Streamlit và evidence hiển thị cho người dùng
13	Khả năng tái lập và cấu trúc repository	Xác định source-of-truth files và trình tự chạy có thể tái lập
14	Hạn chế và lộ trình chuyển sang production	Liệt kê technical debt và yêu cầu trước khi dùng với GSM thực
15	Kết luận	Đánh giá cuối cùng về deliverable kỹ thuật
Phụ lục A	Schema feature và output hiện tại	Data dictionary cho active pipeline
Phụ lục B	Snapshot metrics hiện tại	Metrics được tính lại từ committed dataset và policy logic hiện hành
Phụ lục C	Đối chiếu tài liệu lịch sử	Ghi rõ cách xử lý các điểm stale trong Week 4-6 artifacts
Phụ lục D	Tài liệu tham khảo	Repository và nguồn dữ liệu công khai

1. Tóm tắt điều hành

Dự án GSM Promotion Experimentation là một **sandbox mô phỏng và hỗ trợ ra quyết định end-to-end** cho việc đánh giá các chiến lược khuyến mãi chuyển đi. Implementation hiện tại được xây dựng quanh năm câu hỏi kỹ thuật có liên kết với nhau:

1. Một experiment cần được thiết kế và kiểm tra như thế nào trước khi diễn giải kết quả A/B?
2. Làm thế nào để biểu diễn sự khác biệt về phản ứng của khách hàng trong một môi trường synthetic có kiểm soát?
3. Uplift model có thể xếp hạng người dùng theo **mức tăng chuyển đi kỳ vọng do voucher tạo ra**, thay vì chỉ theo baseline demand hay không?
4. Làm thế nào chuyển predicted incremental rides thành promotion economics và policy targeting?
5. Làm thế nào trình bày statistical evidence và business evidence cho PM/analyst mà không biến synthetic results thành production truth?

Active pipeline sinh một causal dataset gồm **20.000 synthetic users**, trong đó biết trước potential outcomes Y_0 , Y_1 , conditional average treatment effect cate_true , randomized và observational treatment assignment, realized outcomes, behavioral features và các trường unit economics. Nhánh randomized được sử dụng cho experiment health checks và A/B estimation; nhánh observational được giữ để minh họa confounding và **không** được diễn giải tương đương randomized evidence.

Lớp modeling hiện tại sử dụng **simplified R-Learner-style residual learning với XGBoost**. Implementation trước hết ước lượng conditional outcome, sau đó residualize outcome và treatment theo randomized propensity đã biết là 0,5, rồi fit một XGBoost thứ hai để ước lượng heterogeneous treatment effect. Vì script hiện tại chưa triển khai cross-fitting cho nuisance models, tài liệu này **không** gọi implementation là một full cross-fitted Double Machine Learning estimator.

Policy engine so sánh bảy dòng policy: no-voucher baseline, năm candidate targeting strategies và một synthetic-only oracle. Mục tiêu business chính là **expected incremental value ở cấp user**, không chỉ là response probability. Trong committed snapshot hiện tại, Mass Voucher lỗ đáng kể dưới economics của policy engine, trong khi policy dựa trên positive EV cho predicted incremental profit dương và synthetic benchmark profit dương trên holdout set. Bài học chính của decision-support layer là: **predicted uplift cao không đồng nghĩa với targeting có lợi nhuận**.

Do đó, hệ thống hữu ích như một experimentation framework có thể tái lập, nhưng phạm vi kết luận cuối cùng phải được giới hạn rõ:

- workflow được validate trong môi trường synthetic;
- dự án minh họa được cách experiment, uplift, economics và policy liên kết với nhau;
- dashboard hỗ trợ PM/analyst rà soát evidence theo một trình tự rõ ràng;
- dự án **không** chứng minh bất kỳ targeting policy nào sẽ hiệu quả với khách hàng GSM;
- trước deployment cần có randomized GSM data thực, economics được thống nhất, causal-model validation chặt hơn và production monitoring.

2. Phạm vi, Evidence Boundary và Source of Truth

2.1 Phạm vi dự án

Dự án bao phủ analytical workflow từ nền tảng mobility công khai/tham chiếu, qua synthetic causal experiment, đến so sánh promotion policy. Đây **không phải** một production voucher-delivery system và không bao gồm live customer eligibility service, voucher issuance API, online feature store hay production experimentation platform.

Phạm vi kỹ thuật cuối cùng gồm:

- dữ liệu mobility công khai/tham chiếu và EDA;
- sinh feature synthetic ở cấp user;
- synthetic potential outcomes và treatment effects;
- randomized experiment assignment;

- A/A và A/B statistical diagnostics;
- behavioral persona reporting;
- CATE/uplift modeling;
- promotion economics và targeting-policy comparison;
- calibration và Qini-style diagnostics;
- stress testing trong các kịch bản mô phỏng;
- Streamlit decision-support dashboard;
- source code và artifacts có thể tái lập.

2.2 Phạm vi bằng chứng

Dự án chủ động tách ba nhóm bằng chứng.

A. Bằng chứng từ dữ liệu công khai/tham chiếu

Public mobility data có thể hỗ trợ descriptive calibration, feature-engineering ideas và minh họa mobility analysis. Tuy nhiên, dữ liệu này không chứa treatment response ở cấp khách hàng GSM nên không thể xác định causal effect của voucher GSM.

B. Bằng chứng causal tổng hợp

Synthetic DGP tạo Y0, Y1 và cate_true theo thiết kế. Nhờ vậy dự án có thể đánh giá model/policy dựa trên known ground truth và kiểm tra xem experimental pipeline có vận hành đúng như kỳ vọng hay không. Tuy nhiên synthetic ground truth được tạo từ assumptions của dự án, không phải observed customer truth.

C. Bằng chứng production trong tương lai

Muốn rút ra causal conclusion thực tế cho GSM cần có eligible GSM population, pre-treatment features với timestamp hợp lệ, randomized treatment assignment, observed post-treatment outcomes, business economics đã thống nhất và governance cho exposure, attribution, monitoring và policy rollout.

2.3 Thứ tự Source of Truth

Các weekly report cũ vẫn hữu ích để theo dõi quá trình phát triển, nhưng một số assumptions và model names đã thay đổi trong implementation cuối. Khi có mâu thuẫn, tài liệu final sử dụng thứ tự ưu tiên sau:

1. **Active source code** - src/pipeline/main_pipeline.py, src/pipeline/policy_comparison_engine.py, src/dashboard/app.py.
2. **Active configuration** - config.json.
3. **Committed processed dataset hiện tại và policy artifacts hiện hành.**
4. **Tài liệu kỹ thuật final này.**
5. **Weekly reports và specifications cũ** - chỉ được xem là development-history artifacts khi khác active implementation.

Thứ tự này quan trọng vì các tài liệu cũ có nhắc tới 14-day outcome và T-Learner/X-Learner, trong khi implementation hiện tại dùng convention **30-day synthetic outcome** và một **R-Learner-style residual model**.

3. Bài toán nghiệp vụ và kỹ thuật

3.1 Câu hỏi nghiệp vụ

Promotion team không chỉ cần biết **ai có khả năng đi xe nhiều**. Điều cần biết là ai có khả năng tạo ra **chuyển đi tăng thêm nhờ voucher**, và giá trị tăng thêm đó có đủ bù promotion cost hay không.

Ở cấp user, bài toán quyết định có thể biểu diễn như sau:

Target user i nếu $\text{expected incremental business value}_i > 0$,

đồng thời tuân thủ các ràng buộc thực tế như budget, customer eligibility, policy capacity, fairness, experimentation requirements và operational guardrails.

Một targeting strategy đơn giản có thể thất bại vì nhiều nguyên nhân:

- target high-frequency users có thể chỉ trợ giá cho những chuyển vốn sẽ xảy ra dù không có voucher;
- target toàn bộ users có thể làm tăng số chuyển nhưng phá hủy contribution margin;
- target người có predicted uplift cao nhất vẫn có thể lỗ nếu fare, margin và voucher cost khác nhau giữa users;
- observational correlation giữa voucher receipt và outcome có thể bị confounding;
- assignment không ổn định hoặc covariates mất cân bằng có thể làm experiment không còn hợp lệ trước cả khi modeling bắt đầu.

3.2 Mục tiêu kỹ thuật

Dự án vì vậy triển khai bốn lớp ngày càng mạnh hơn.

Lớp 1 - Experiment Validity

Kiểm tra sample ratio, covariate balance, A/A behavior và A/B estimation trước khi diễn giải heterogeneous response.

Lớp 2 - Heterogeneous Treatment Effect

Ước lượng incremental response thay đổi thế nào theo pre-treatment user context, thay vì coi population ATE là đủ cho targeting.

Lớp 3 - Economics

Chuyển predicted CATE thành expected incremental contribution sau voucher cost.

Lớp 4 - Policy


So sánh các targeting rules khác nhau trên cùng holdout population và cùng synthetic ground truth.

3.3 Đơn vị phân tích và outcome chính

Active synthetic pipeline hoạt động ở **cấp user**. Outcome chính là số chuyển đi trong **30 ngày**. Treatment chính là binary promotion/voucher assignment. Phân tích phân biệt rõ:

- potential outcome khi không có treatment: Y_0 ;
 - potential outcome khi có treatment: Y_1 ;
 - realized randomized outcome: Y_{rand} ;
 - true conditional expected treatment effect: cate_true ;
 - realized individual difference trong simulator: $\text{ite_realized} = Y_1 - Y_0$.
-

4. Kiến trúc hệ thống hiện tại



Kiến trúc end-to-end hiện tại

Hình 1. Kiến trúc end-to-end hiện tại. Kiến trúc tách data generation, causal experiment logic, heterogeneous treatment-effect modeling, business policy evaluation và decision-support presentation.

4.1 Luồng kiến trúc

Implementation hiện tại chạy theo trình tự:

1. **Reference data và EDA** cung cấp descriptive context và calibration ideas.
2. **Synthetic feature generation** tạo các pre-treatment covariates ở cấp user.
3. **Synthetic causal DGP** sinh Y0, Y1 và cate_true.
4. **Randomized treatment assignment** tạo nhánh experimental hợp lệ.
5. **Experiment diagnostics** kiểm tra A/A behavior, SRM, covariate balance và A/B effects.
6. **Behavioral personas** tạo reporting và interpretation layer.
7. **R-Learner-style CATE modeling** ước lượng heterogeneous response trên holdout split.
8. **Economics engine** chuyển CATE thành expected incremental value.
9. **Policy engine** so sánh mass, segment, uplift, profit, budget và oracle rules.
10. **Streamlit dashboard** trình bày evidence và policy outputs cho PM/analyst.

4.2 Phân tách trách nhiệm giữa các thành phần

Dự án chủ động tách data generation khỏi modeling.

- `main_pipeline.py` chịu trách nhiệm synthetic DGP, experiment assignment, outcome realization, persona labels và processed dataset export.
- `policy_comparison_engine.py` chịu trách nhiệm model training, holdout prediction, expected-value calculation, policy selection, calibration/Qini exports và oracle regret.
- `app.py` chịu trách nhiệm decision-support interface và đọc precomputed evidence thay vì trở thành một modeling pipeline thứ hai.

Cách tách này giúp giảm nguy cơ model leakage và làm rõ ranh giới giữa **ground-truth generation** với **model estimation**.

4.3 Nguyên tắc thiết kế

Kiến trúc tuân theo một nguyên tắc trung tâm:

Causal model ước lượng incremental response; policy layer quyết định incremental response đó có đáng để chi tiền mua hay không.

Sự phân biệt này quan trọng hơn việc tối đa hóa một predictive score đơn lẻ.

5. Nền tảng dữ liệu và hiệu chỉnh

5.1 Lớp dữ liệu mobility công khai/tham chiếu

Dự án sử dụng NYC Taxi & Limousine Commission trip-record data làm nguồn mobility công khai/tham chiếu. Dữ liệu gồm thời gian chuyến đi, trip distance, fare, payment information, passenger count và các thuộc tính liên quan. EDA của project được thực hiện trên khoảng **3,04 triệu cleaned trip records** trong reference workflow.

Reference data phục vụ ba mục tiêu:

- minh họa realistic mobility EDA và feature-engineering workflow;
- cung cấp plausible ranges và relationships cho synthetic variables;
- tạo nền tảng demo không nhạy cảm và có thể tái lập.

Dữ liệu này **không** cung cấp causal treatment response ở cấp khách hàng GSM.

5.2 Synthetic population hiện tại

Committed processed dataset hiện tại gồm **20.000 synthetic users**. Synthetic feature set được thiết kế để biểu diễn heterogeneous travel context và customer behavior trong khi vẫn tái lập được với fixed seed.

Các pre-treatment features chính gồm:

- age;
- urban/suburban indicator;
- weekend tendency;
- rain context;
- airport tendency;
- payment type;
- passenger count;
- preferred travel hour;
- monthly ride history;
- recency in days;
- derived rush và leisure indicators.

5.3 Vì sao sử dụng synthetic data

Synthetic causal data giải quyết một vấn đề đánh giá rất cụ thể: real-world datasets thông thường không cho phép quan sát đồng thời cả hai potential outcomes của cùng một người. Trong simulator, cả Y0 và Y1 đều được tạo ra, nên dự án có thể:

- biết treatment effect kỳ vọng theo thiết kế;
- tính synthetic oracle policies;
- đo model calibration so với cate_true;
- đánh giá policy regret so với oracle;
- kiểm tra randomized estimator qua repeated simulation.

Trade-off cũng cần được nêu rõ: model performance phụ thuộc vào assumptions của DGP.

5.4 Kiểm tra snapshot hiện tại

Từ committed processed dataset gồm 20.000 users:

Kiểm tra	Giá trị hiện tại	Diễn giải
Users	20.000	Active synthetic population
Randomized treated users	10.000	Chính xác 50% treatment share
Randomized control users	10.000	Chính xác 50% control share
Mean Y0	7,995 rides	Phù hợp configured baseline gần 8 rides / 30 days
Tỷ lệ zero trong Y0	20,0%	Phù hợp targeted zero-inflation rate
Mean cate_true	0,800 rides	Khớp DGP calibration target
Mean realized Y1 - Y0	0,931 rides	Finite-sample difference; theo thiết kế không bắt buộc bằng expected CATE
Mean fare / trip	USD 26,28	Synthetic fare context dùng cho economics

Cần phân biệt rõ **expected treatment effect** (cate_true) với **realized finite-sample individual difference** (Y1 - Y0). Khi outcome generator mang tính stochastic, realized sample difference không nhất thiết bằng chính xác designed mean CATE.

6. Quy trình sinh dữ liệu causal tổng hợp

6.1 Causal sequence

Active DGP tuân theo trình tự:

Pre-treatment X -> Y0 distribution -> CATE_true -> Y1 distribution -> treatment assignment -> observed outcome

Simulator không sinh observed outcome trước rồi suy ngược treatment effect. Treatment effect là một phần của controlled DGP, nhờ đó có thể đánh giá model/policy so với synthetic ground truth.

6.2 Baseline potential outcome Y0

Baseline monthly rides được sinh theo cấu trúc **zero-inflated negative binomial**. Conditional mean phụ thuộc vào các pre-treatment features như ride-history intensity, urban context và recency.

Biểu diễn rút gọn:

$$\mu_0(X) = 8 * \exp(\beta_{\text{history}} * z_{\text{history}} + \beta_{\text{urban}} * z_{\text{urban}} + \beta_{\text{recency}} * z_{\text{recency}})$$

sau đó áp dụng calibrated zero inflation và negative-binomial sampling.

Active configuration hướng tới:

- baseline mean gần 8 rides / 30 days;
- khoảng 20% structural zeros;
- over-dispersion thông qua negative-binomial component.

Cấu trúc này phù hợp hơn simple Poisson DGP cho sandbox vì ride count có thể over-dispersed và có zero mass đáng kể.

6.3 Conditional treatment effect cate_true

DGP tạo heterogeneous treatment response từ tổ hợp main effects và interactions. Các mechanisms hiện tại gồm sự khác biệt phản ứng liên quan đến:

- age sensitivity;
- diminishing response khi ride history cao;
- rain-by-age interaction;
- suburban-by-weekend interaction;
- recency-related reactivation potential;
- penalties gắn với airport, rush-hour và cash-related contexts.

Raw effect được giới hạn không âm, sau đó scale numerically để population mean expected CATE xấp xỉ **0,8 rides/user/30 days**.

Effect function này là **simulation assumption**, không phải empirical estimate từ khách hàng GSM.

6.4 Treated potential outcome Y1

Treatment potential outcome được sinh từ treatment-shifted outcome distribution. Một treatment-related wake mechanism làm giảm dormant probability với một số users, đồng thời conditional ride mean tăng phù hợp với designed effect.

Simulator lưu cả Y0 và Y1, cho phép synthetic oracle comparison - điều bình thường không có trong real-world dataset.

6.5 Treatment assignment

Nhánh randomized

Primary experimental branch sử dụng stratified randomization theo ride-history và recency strata, mục tiêu exact 50/50 treated-control allocation. Realized outcome:

$Y_rand = treatment_rand * Y1 + (1 - treatment_rand) * Y0$.

Đây là source phù hợp cho A/B estimation và R-Learner training trong sandbox hiện tại.

Nhánh observational

Một observational treatment assignment riêng được sinh kèm confounding và được calibrate để tổng số treated gần tương đương randomized branch. Nhánh này dùng để minh họa vì sao observational treatment assignment có thể khác randomized evidence. Không được trộn nhánh observational vào nhánh randomized khi đánh giá experimental causal claims.

6.6 Các trường unit economics do DGP sinh ra

DGP đồng thời tạo synthetic average fare per trip và contribution fields. Fare thay đổi theo context như airport/urban/suburban pattern và rush-hour surge behavior. Main DGP tính per-trip voucher discount theo:

$\min(\text{avg_fare} * \text{voucher_rate}, \text{USD } 3.00)$.

Cost definition này hiện **không hoàn toàn giống** uncapped promotion-cost convention của policy comparison engine. Mismatch được ghi rõ là technical debt ở Phần 14; trước khi diễn giải production cần thống nhất thành một cost function duy nhất.

7. Experimentation và kiểm định thống kê

7.1 Thứ tự kiểm định

Dự án sử dụng validity-first workflow:

Design -> A/A -> SRM -> Covariate Balance -> A/B -> Heterogeneity -> Economics -> Policy

Cách làm này ngăn việc diễn giải một A/B result có ý nghĩa thống kê trước khi chất lượng assignment được kiểm tra.

7.2 A/A Testing

A/A testing kiểm tra xem randomization và analysis pipeline có tạo false treatment effect một cách hệ thống khi hai nhóm về mặt thống kê là tương đương hay không.

Một Week 4 calibration artifact trước đây đã chạy **5.000 A/A iterations** và ghi nhận false-positive rate gần nominal 5%. Đây là evidence hữu ích cho pipeline, nhưng chỉ nên xem là development diagnostic chứ không phải production experiment result. Nếu thay đổi SRM threshold hoặc significance alert threshold, repeated-test baseline tương ứng cần được hiệu chỉnh lại.

7.3 Sample Ratio Mismatch (SRM)

SRM được kiểm tra bằng chi-square test, so sánh observed treatment allocation với designed allocation. SRM alert cho thấy assignment/exposure pipeline có thể không khớp intended randomization.

Trong committed dataset hiện tại, randomized assignment đúng **10.000 treated / 10.000 control**, phù hợp thiết kế 50/50.

7.4 Covariate Balance

Pre-treatment balance được đánh giá bằng **Standardized Mean Difference (SMD)**. Project sử dụng $|SMD| < 0,10$ như practical balance guideline.

Trong snapshot hiện tại, absolute SMD lớn nhất trong các pre-treatment checks chính khoảng **0,033**, thấp hơn đáng kể 0,10. Kết quả này hỗ trợ internal balance của randomized split.

7.5 A/B Effect Estimation

Primary synthetic outcome là 30-day ride count. Trên committed randomized snapshot, simple unadjusted treated-control difference là:

- ATE estimate: **0,963 rides/user/30 days**;
- 95% confidence interval: **[0,744; 1,182]**;
- Welch-test p-value: **< 0,001**.

Estimate khác designed mean cate_true = 0,800 vì observed A/B contrast là finite-sample contrast của stochastic potential outcomes, trong khi cate_true là expected conditional effect từ DGP.

Dashboard chủ động dùng simple A/B view để dễ diễn giải. Phân tích Week 4 trước đây còn sử dụng covariate-adjusted regression với heteroskedasticity-robust inference. Đây là các analysis layers bổ sung cho nhau, không phải hai định nghĩa outcome cạnh tranh nhau.

7.6 Monte Carlo Validation

Active main pipeline bao gồm repeated validation của randomized estimator bằng fixed synthetic Y0 và Y1 ground truth. Mục tiêu là đánh giá estimator behavior như:

- bias qua repeated assignments;
- confidence-interval coverage;

- power dưới configured effect size.

Điểm mạnh của synthetic environment là biết potential outcomes. Tuy nhiên Monte Carlo validation vẫn không thay thế external validation bằng real randomized experiment.

8. Phân khúc hành vi

8.1 Vai trò của segmentation

Segmentation là **reporting và interpretation layer**, không phải causal targeting model chính. Cách đặt này tránh một lỗi phổ biến: cho rằng behavioral similarity đồng nghĩa treatment-response similarity.

Các giai đoạn đầu của dự án đã dùng K-Means để khám phá behavioral structure. Active main pipeline hiện gán stable deterministic behavioral personas để dashboard reporting có thể tái lập qua các lần rerun DGP.

8.2 Active personas hiện tại

Committed processed dataset hiện có năm personas:

Persona	Users	Tỷ trọng
Urban Regulars	8.568	42,8%
Suburban Cash	5.381	26,9%
Suburban Card	2.680	13,4%
Rain Riders	2.651	13,3%
Airport Business	720	3,6%

Active rule logic dựa trên các behavioral/context features hiện tại như urban status, payment type, rain và airport tendency.

8.3 Cách diễn giải đúng

Personas có thể trả lời các câu hỏi như:

- Synthetic population đang chứa những user contexts nào?
- A/B effects và economics khác nhau thế nào giữa các behavioral groups để hiểu?
- Group definitions nào hữu ích cho PM reporting?

Personas **không** trả lời được:

- User cụ thể nào nên nhận voucher?
- User nào có causal treatment effect cao nhất?
- Targeting rule nào tối đa hóa profit?

Các câu hỏi đó thuộc uplift và policy layers.

9. Uplift / CATE Modeling

9.1 Mục tiêu modeling

Model ước lượng heterogeneous incremental rides:

$$\tau(X) = E[Y(1) - Y(0) | X].$$

Mục tiêu không phải chỉ dự đoán tổng số chuyến. Một user có thể có baseline demand cao nhưng incremental response thấp; ngược lại một user có baseline demand thấp vẫn có thể phản ứng mạnh với voucher.

9.2 Estimator hiện tại

Active policy engine triển khai **simplified R-Learner-style residual learner** sử dụng XGBoost.

Training logic gồm:

1. Fit outcome model $m(X)$ trên training set.
2. Sử dụng randomized propensity đã biết $e(X) = 0.5$.
3. Tính residualized outcome:
 $Y_tilde = Y - m(X)$.
4. Tính residualized treatment:
 $T_tilde = T - 0.5$.
5. Tạo pseudo-outcome:
 $uplift_target = Y_tilde / T_tilde$.
6. Fit XGBoost regressor thứ hai với weights T_tilde^2 .
7. Predict CATE trên untouched holdout test set.

Implementation được gọi là **R-Learner-style** thay vì full Double Machine Learning estimator vì hiện chưa có nuisance-model cross-fitting.

9.3 Data split

Script hiện tại tạo gần đúng:

- 60% training split;
- 20% validation split;
- 20% final holdout test split.

Với 20.000 users, final holdout gồm 4.000 users. Validation partition đã được dành riêng trong split logic; tuy nhiên R-Learner script hiện dùng fixed hard-coded XGBoost parameters và chưa sử dụng validation partition cho systematic tuning hoặc early stopping. Điểm này được ghi rõ là technical debt thay vì che giấu.

9.4 Predictive diagnostics hiện tại

So với known synthetic cate_true trên holdout 4.000 users, snapshot hiện tại đạt xấp xỉ:

Diagnostic	Giá trị	Diễn giải
CATE RMSE	0,754	Level error vẫn đáng kể
CATE MAE	0,564	Absolute error không nhỏ
Pearson correlation	0,286	Linear agreement với synthetic truth ở mức vừa phải
Spearman correlation	0,309	Có ranking signal dương nhưng chưa mạnh

Các diagnostics này hỗ trợ một kết luận thận trọng: model có useful ranking information trong simulator, nhưng CATE level calibration chưa hoàn hảo. Vì vậy bước đúng tiếp theo không phải claim rằng individual treatment effects đã rất chính xác, mà là kiểm tra xem ranking và resulting policy có thực sự hữu ích hay không.

9.5 Qini và calibration outputs

Policy engine export:

- decile-based uplift calibration table;
- Qini curve artifact;
- holdout predictions chứa cate_pred và synthetic cate_true.

Implementation hiện tại export **Qini curve**, nhưng chưa persist scalar AUUC/Qini coefficient như canonical project metric. Vì vậy tài liệu final không tự tạo một con số AUUC không có trong source of truth.

10. Unit Economics và Policy Optimization

10.1 Vì sao economics phải đi sau uplift

CATE cao chưa đủ để quyết định phát voucher. Incremental rides phải tạo đủ contribution để bù promotion cost.

Với user i , policy engine tính:

$\text{margin_per_ride}_i = \text{avg_fare}_i * \text{margin_rate}$

$\text{voucher_cost_per_ride}_i = \text{avg_fare}_i * \text{voucher_rate}$

và expected incremental value:

$\text{EV}_i = \text{cate_pred}_i * \text{margin_per_ride}_i - \text{pred_rides_treated}_i * \text{voucher_cost_per_ride}_i$.

Các economics assumptions có thể cấu hình hiện tại gồm:

- voucher rate: **15%**;
- contribution margin rate: **70%**;
- budget limit: **USD 50.000**.

Đây là **sandbox assumptions**, không phải economics đã được GSM xác nhận cho production.

10.2 Định nghĩa các policy

Current engine so sánh các rules sau trên cùng holdout population.

0. No Voucher

Không target user nào. Dùng làm zero-increment baseline.

1. Mass Voucher

Target toàn bộ users. Policy này đo chi phí của broad promotion exposure.

2. Segment Targeting

Target users có active persona chứa nhãn Suburban. Đây là interpretable rule-based benchmark.

3. Uplift Targeting

Target top 30% users theo predicted CATE. Mục tiêu là kiểm tra xem ranking theo response đơn thuần có tốt hơn mass targeting hay không.

4. Profit Targeting

Target users có predicted expected value dương:

$\text{EV}_i > 0$.

5. Budget-Constrained Targeting

Trong nhóm positive-EV users, sort theo predicted EV và chọn users trong khi cumulative expected voucher cost vẫn nằm trong configured budget.

6. Oracle

Sử dụng synthetic cate_true để chọn users có positive synthetic oracle EV. Policy này chỉ tồn tại **vì simulator biết ground truth** và không phải một deployable real-world policy.


10.3 Business metrics

Với mỗi policy, engine báo cáo các metrics như:

- target size và target rate;
- predicted incremental profit;
- synthetic benchmark profit;
- incremental rides;
- incremental GMV;
- voucher burn;
- cost per incremental ride (CPIR);
- burn / GMV;
- burn / incremental GMV;
- ROI;
- approximate uncertainty band quanh predicted policy value.

Current uncertainty band chỉ là dispersion-based approximation đơn giản quanh tổng expected value. Nó nên được xem là dashboard diagnostic, không phải production-grade causal policy-value confidence interval.

10.4 So sánh policy hiện tại



So sánh profit giữa các policy hiện tại

Hình 2. So sánh policy profit trên holdout 4.000 users hiện tại. Oracle dùng synthetic truth và chỉ được hiển thị như benchmark.

Policy	Target rate	Incremental rides	Voucher burn	Predicted incremental profit	Synthetic benchmark profit	ROI
No Voucher	0,0%	0	USD 0	USD 0	USD 0	-
Mass Voucher	100,0%	3.821	USD 132.133	-USD 65.358	-USD 76.313	-49,5%
Segment Targeting	41,5%	1.437	USD 35.280	-USD 4.286	-USD 996	-12,1%
Uplift Top 30%	30,0%	2.021	USD 43.210	-USD 10.187	-USD 25.360	-23,6%
Profit Targeting	22,2%	1.112	USD 14.666	USD 7.939	USD 7.060	54,1%
Budget-Constrained	22,2%	1.112	USD 14.666	USD 7.939	USD 7.060	54,1%

Policy	Target rate	Incremental rides	Voucher burn	Predicted incremental profit	Synthetic benchmark profit	ROI
Oracle - synthetic only	25,0%	1.017	USD 14.902	USD 4.971	USD 10.818	33,4%*

* Oracle không phải deployable policy; synthetic benchmark value mới là comparison phù hợp.

Configured budget USD 50.000 **không binding** trong holdout hiện tại vì positive-EV policy chỉ sử dụng khoảng USD 14.666 voucher burn. Do đó Profit Targeting và Budget-Constrained Targeting chọn cùng một tập users trong snapshot này.

10.5 Oracle Regret

Theo synthetic benchmark profit, Profit Targeting hiện đạt khoảng USD 7.060 so với USD 10.818 của synthetic oracle. Regret còn lại xấp xỉ:

USD 10.818 - USD 7.060 = USD 3.758,

hay khoảng **34,7% oracle value**.

Khoảng cách này hữu ích cho diagnostics: nó lượng hóa dư địa cải thiện ranking/calibration **bên trong simulator** mà không giả định rằng oracle value tồn tại trong production data thực.

11. Đánh giá và kiểm tra độ bền vững

11.1 Triết lý đánh giá

Dự án tách bốn câu hỏi riêng thay vì rút tất cả về một score duy nhất:

1. **Experiment validity:** assignment có khỏe về mặt thống kê hay không?
2. **CATE quality:** model có recover heterogeneous response signal hay không?
3. **Policy value:** targeting có cải thiện business economics hay không?
4. **Robustness:** conclusions có giữ được qualitatively dưới simulated perturbations hay không?

11.2 Model evidence hiện tại

R-Learner-style model hiện có correlation dương nhưng vừa phải với synthetic CATE. Mức này đủ để justify policy evaluation, nhưng chưa đủ để claim accurate individual causal effects.

Qini curve và decile calibration output cung cấp ranking và level diagnostics. Khi ranking có ích nhưng level calibration chưa hoàn hảo, expected-value thresholds vẫn có thể nghiên cứu, nhưng cần được validate bằng holdout/off-policy methods và cuối cùng bằng real randomized policy experiment.

11.3 Policy evidence hiện tại

Holdout hiện tại minh họa ba behavior quan trọng:

- **Mass promotion có thể phá hủy economics** ngay cả khi average treatment effect dương.
- **Top-uplift targeting không tự động có lợi nhuận** vì incremental response cao nhất vẫn có thể quá đắt để trợ giá.
- **Profit-aware targeting có thể tốt hơn response-only targeting** khi expected margin và voucher cost được đưa trực tiếp vào quyết định.

Đây là synthetic demonstration của decision logic, không phải GSM business recommendation.

11.4 Stress Testing

Project có simulation stress tests cho các kịch bản như:

- sample sizes khác nhau;
- null/A-A conditions;
- treatment imbalance;
- additional outcome noise.

Kết luận đúng cần được giới hạn: **không phát hiện material instability trong các simulated scenarios đã đánh giá**. Các tests này hỗ trợ internal robustness của sandbox workflow; chúng không chứng minh production readiness hay external causal validity.

11.5 Những điều dự án chủ động không claim

Dự án không claim:

- real GSM uplift accuracy;
- real customer ROI;
- production-safe individualized causal inference;
- universal transferability từ NYC/reference mobility behavior sang GSM;
- sẵn sàng automated voucher deployment nếu chưa có các controls bổ sung.

12. Dashboard và lớp hỗ trợ ra quyết định

12.1 Mục đích

Streamlit application được thiết kế như một **decision-support interface**, không phải modeling logic source thứ hai. App đọc precomputed evidence và trình bày project theo đúng thứ tự PM nên review: data foundation trước, experiment health trước effect, heterogeneous response trước policy, và economics trước recommendation.

12.2 Navigation hiện tại

Dashboard hiện có tám functional areas:

1. **Data Foundation** - giải thích ranh giới giữa public/reference data và synthetic data.
2. **Experiment Setup** - trình bày design logic và sample-size/MDE concepts.
3. **Experiment Health** - hiển thị SRM và covariate-balance diagnostics.
4. **A/B Results** - trình bày overall experiment effect và business translation.
5. **Heterogeneous Response** - trình bày behavioral personas và model diagnostics.
6. **Policy Comparison** - so sánh candidate strategies với synthetic oracle benchmark.
7. **Policy Simulator** - cho phép thay đổi economic constraints và quan sát policy behavior.
8. **Developer Tools** - cung cấp implementation context trong khi vẫn kiểm soát public rerun behavior.

12.3 Evidence hierarchy trên dashboard

Dashboard nên được đọc theo cùng logic với technical pipeline:

Có thể tin assignment không? -> Có average effect không? -> Response có heterogeneous không? -> Ranking có ích không? -> Policy có tạo value không?

Trình tự này tránh việc PM nhìn thấy một policy number hấp dẫn trước khi biết experiment và evidence có hợp lệ hay không.

12.4 Static và interactive outputs

Canonical static policy comparison được tạo bởi policy engine và persist thành artifacts. Simulator tính lại policy behavior theo economics do người dùng lựa chọn. Static engine vẫn là source of truth cho final benchmark numbers vì có thể tái lập hoàn toàn từ current code và holdout split.

Trước khi productionize, input schema của simulator và static policy-export schema cần được đồng bộ hoàn toàn để các benchmark strategies được biểu diễn nhất quán giữa static và interactive views.

13. Khả năng tái lập và cấu trúc repository

13.1 Active source-of-truth files

File	Trách nhiệm
src/pipeline/main_pipeline.py	Synthetic DGP, treatment assignment, outcomes, personas, processed dataset, repeated RCT validation
src/pipeline/policy_comparison_engine.py	R-Learner-style model, holdout predictions, economics, policies, calibration/Qini, oracle regret
src/dashboard/app.py	Streamlit decision-support interface
config.json	Active global configuration như economics và feature definitions
data/processed/segmented_simulation_data.csv	Committed synthetic user-level dataset hiện tại
outputs/policy_comparison.csv	Canonical static policy comparison khi regenerate
outputs/test_predictions.csv	Holdout predictions cho diagnostics/simulation
outputs/uplift_calibration.csv	Decile calibration artifact
outputs/qini_curve.csv	Qini curve coordinates
outputs/oracle_regret.json	Synthetic oracle regret summary

13.2 Trình tự chạy có thể tái lập

Intended local execution order:

```
python src/pipeline/main_pipeline.py
python src/pipeline/policy_comparison_engine.py
streamlit run src/dashboard/app.py
```

Lệnh thứ nhất regenerate synthetic dataset. Lệnh thứ hai train current CATE model và regenerate policy artifacts. Lệnh thứ ba launch dashboard từ các artifacts đó.

13.3 Randomness và deterministic behavior

Main simulation dùng fixed project seed để hỗ trợ reproducibility. Vì XGBoost và simulation components có thể có implementation-level nondeterminism giữa các environment/library versions, không nên giả định exact bitwise equality trên mọi máy. Yêu cầu hợp lý là **reproducible analytical behavior**, stable schema và metrics nhất quán về mặt thực chất trong documented environment.

13.4 Dependency và environment governance

Nếu handoff theo production-grade standard, project nên pin thêm:

- Python version;
- exact package versions;
- XGBoost version;
- Streamlit version;
- OS/runtime assumptions;

- seed và deterministic training options nếu có.

Một lock file hoặc fully pinned environment specification sẽ tăng repeatability so với general requirements file.

14. Hạn chế và lộ trình chuyển sang production

14.1 Các hạn chế implementation đã biết

1. Chỉ có synthetic evidence

Hạn chế lớn nhất không nằm ở thống kê mà ở data boundary. cate_true, oracle value và policy regret tồn tại vì project tự tạo causal ground truth. Dữ liệu GSM thực sẽ không có những labels này.

2. R-Learner implementation chưa có cross-fitting

Current model residualize training data bằng outcome model được fit trên chính training partition đó. Đây là implementation hữu ích cho sandbox nhưng chưa phải full cross-fitted R-Learner/DML workflow.

Bước cải thiện đề xuất: triển khai K-fold cross-fitting cho nuisance predictions và so sánh với doubly robust hoặc causal-forest baseline.

3. Validation split chưa được sử dụng tích cực cho tuning

Mặc dù script tạo train/validation/test partitions, current model hyperparameters vẫn fixed trong code và validation set chưa được dùng cho systematic early stopping hoặc model selection.

Bước cải thiện đề xuất: dùng validation để model selection nhưng giữ nguyên final 20% test set cho one-time policy evaluation.

4. config.json chưa phải source duy nhất cho active R-Learner parameters

Active policy engine còn hard-code một số XGBoost parameter choices khác với model_params block trong config.json.

Bước cải thiện đề xuất: chuyển toàn bộ active model parameters về một configuration source duy nhất và log resolved configuration cùng mỗi artifact.

5. Voucher cost giữa DGP và policy engine chưa được thống nhất hoàn toàn

DGP field discount_cost_30d dùng per-trip cap USD 3, trong khi policy engine dùng uncapped avg_fare * voucher_rate cost convention cho expected value.

Do đó DGP net_contribution và policy-engine predicted incremental profit **không thể coi là hoàn toàn interchangeable**.

Bước cải thiện đề xuất: định nghĩa một canonical voucher-cost function duy nhất và tái sử dụng trong cả data generation lẫn policy evaluation.

6. Qini curve chưa có canonical scalar AUUC metric

Project có thể visualize ranking quality nhưng chưa persist một standardized scalar uplift-ranking metric như source-of-truth artifact.

Bước cải thiện đề xuất: persist Qini coefficient/AUUC kèm confidence intervals hoặc repeated-split uncertainty.

7. Policy-value uncertainty hiện chỉ là xấp xỉ

Current expected-value uncertainty band dùng simple dispersion approximation. Nó chưa phản ánh đầy đủ uncertainty từ CATE estimation, policy selection hoặc dependence do model fitting.

Bước cải thiện đề xuất: đánh giá policy bằng bootstrap, cross-fitting, inverse-propensity/doubly robust policy-value estimators hoặc một randomized policy experiment mới.

8. Historical documentation không nhất quán với final implementation

Các file cũ còn nhắc T-Learner, X-Learner, 14-day outcomes và week-number labels không còn khớp active code. Tài liệu final này giải quyết các conflicts đó, nhưng repo nên archive hoặc label rõ historical reports để tránh ambiguity về sau.

14.2 Các yêu cầu trước khi sử dụng với GSM thực

Production migration tối thiểu cần các gates sau.

Data và identity

- approved GSM user-level schema;
- stable customer identity và eligibility logic;
- treatment/exposure logs có timestamps;
- enforcement pre-treatment feature cutoff;
- post-treatment outcome attribution;
- privacy, retention và access-control review.

Experiment design

- explicit experiment ID và versioning;
- randomized assignment kèm exposure integrity checks;
- primary outcome và guardrail definitions được thống nhất trước launch;
- sample-size / MDE planning;
- SRM và balance monitoring;
- pre-specified subgroup và multiple-testing policy.

Causal modeling

- cross-fitted nuisance models;
- so sánh R-Learner với DR-Learner/causal forest hoặc các baseline có lý do phù hợp;
- calibration và ranking evaluation trên untouched data;
- stability theo thời gian, geography và customer cohorts;
- leakage tests và feature-availability checks.

Economics

- một approved voucher-cost function;
- confirmed contribution-margin definition;
- quy tắc xử lý refund/cancellation và unused voucher;
- phân biệt incremental GMV với incremental contribution;
- budget, capacity và campaign constraints.

Policy validation

- offline policy value với uncertainty có cơ sở;
- shadow-mode evaluation nếu phù hợp;
- randomized champion/challenger policy test;
- incremental-profit và guardrail monitoring;
- rollback criteria và human approval cho material policy changes.

14.3 Trình tự production được khuyến nghị

Final project nên được xem là một **prototype decision framework**. Trình tự hợp lý tiếp theo:

Synthetic validation -> Real randomized A/B -> Heterogeneity validation -> Offline policy evaluation -> Randomized policy test -> Controlled rollout.

Nếu bỏ qua các real randomized stages, một sandbox có cấu trúc tốt sẽ bị biến thành production claim không có đủ căn cứ.

15. Kết luận

Final GSM Promotion Experimentation repository thể hiện một technical path nhất quán từ experiment design đến promotion-policy economics. Điểm mạnh nhất của project không nằm ở một model score duy nhất, mà nằm ở **separation of concerns**:

- randomized evidence thiết lập causal identification;
- synthetic DGP cung cấp known ground truth cho development;
- behavioral personas hỗ trợ interpretation nhưng không bị nhầm với causal targeting;
- R-Learner-style model ước lượng heterogeneous response;
- economics layer chuyển response thành value;
- policy engine so sánh decisions thay vì chỉ so predictions;
- dashboard trình bày evidence theo thứ tự phù hợp cho PM review.

Snapshot hiện tại cũng cho thấy vì sao sự phân tách này quan trọng. Positive average treatment effect không làm Mass Voucher tự động có lợi nhuận, và top-uplift rule không nhất thiết tối đa hóa business value. Profit-aware rule tốt hơn trong simulator hiện tại vì kết hợp incremental response với margin và voucher cost.

Vì vậy project **đã sẵn sàng ở vai trò một final simulation-based technical deliverable và decision-support prototype**. Project **chưa phải bằng chứng cho production deployment trên khách hàng GSM**. Phase tiếp theo cần tập trung vào real randomized data, harmonized economics, cross-fitted causal modeling, policy-value uncertainty có cơ sở và controlled online validation.

Phụ lục A. Schema feature và output hiện tại

A.1 Core pre-treatment features

Field	Vai trò	Ghi chú
age	Feature	Synthetic customer age
is_urban	Feature	Urban/suburban context
is_weekend	Feature	Weekend tendency/context
is_rain	Feature	Rain-related context
is_airport	Feature	Airport-related behavior/context
payment_type	Feature	Encoded payment behavior
passenger_count	Feature	Typical passenger count
preferred_hour	Feature	Preferred travel hour
monthly_rides_history	Feature	Pre-treatment ride-frequency history
recency_days	Feature	Days since recent activity
is_rush	Derived feature	Rush-hour context
is_leisure	Derived feature	Leisure-time context

A.2 Causal ground-truth và experiment fields

Field	Ý nghĩa
Y0	Synthetic potential outcome khi không có voucher

Field	Ý nghĩa
Y1	Synthetic potential outcome khi có voucher
cate_true	Expected conditional treatment effect do DGP định nghĩa
ite_realized	Realized simulator difference Y1 - Y0
treatment_rand	Randomized treatment assignment
Y_rand	Realized randomized outcome
treatment_obs	Confounded observational assignment
propensity_true	Known observational treatment propensity
Y_obs	Realized observational outcome

A.3 Economics và reporting fields

Field	Ý nghĩa
persona	Behavioral reporting persona
avg_fare_per_trip	Synthetic user-level average fare
gross_revenue_30d	Synthetic gross revenue trong analysis horizon
discount_cost_30d	DGP-side voucher cost theo DGP cost convention
net_contribution	DGP-side synthetic contribution field

Phụ lục B. Snapshot metrics hiện tại

B.1 Randomized experiment snapshot

Metric	Giá trị hiện tại
Population	20.000 users
Treatment / control	10.000 / 10.000
A/B ATE	0,963 rides/user/30d
A/B 95% CI	[0,744; 1,182]
Maximum main-feature absolute SMD	0,033
Designed mean cate_true	0,800 rides/user/30d

B.2 CATE holdout snapshot

Metric	Giá trị hiện tại
Test users	4.000
CATE RMSE	0,754
CATE MAE	0,564
Pearson correlation	0,286
Spearman correlation	0,309

B.3 Policy snapshot

Metric	Profit Targeting	Mass Voucher
Target rate	22,2%	100,0%

Metric	Profit Targeting	Mass Voucher
Incremental rides	1.112	3.821
Voucher burn	USD 14.666	USD 132.133
Predicted incremental profit	USD 7.939	-USD 65.358
Synthetic benchmark profit	USD 7.060	-USD 76.313
ROI	54,1%	-49,5%

Các metrics này được tính lại từ current committed synthetic dataset và active policy-engine logic để phục vụ tài liệu final. Đây là **sandbox metrics**, không phải GSM production KPIs.

Phụ lục C. Đối chiếu tài liệu lịch sử

Final documentation chủ động hiệu chỉnh các inconsistency trong development history như sau:

Historical item	Cách diễn giải trong bản final
TECHNICAL_DOCUMENTATION_W4.md mô tả snapshot Week 4	Giữ như historical artifact; tài liệu này bao phủ full active pipeline
Week 5 material cũ nhắc T-Learner	Active policy code dùng R-Learner-style residual model
Specification cũ nhắc X-Learner	Không phải active final implementation
Một số metrics cũ dùng 14-day window	Active synthetic pipeline và dashboard dùng 30-day primary outcome convention
Một số Week 5/6 documents ghi Week 7/8	Xem là labeling error/history, không phải final project chronology
Stress-test text cũ hàm ý broad deployment readiness	Final conclusion chỉ giới hạn ở internal simulated robustness
Persona counts cũ khác hiện tại	Current persona counts lấy từ active committed processed dataset
Persona ROI tables cũ khác hiện tại	Final business metrics dùng current dataset và current policy logic

Phụ lục này nên được giữ trong final technical documentation để reviewer hiểu vì sao old weekly files không phải lúc nào cũng khớp final code behavior.

Phụ lục D. Tài liệu tham khảo

1. Project repository: <https://github.com/thaibuivan/GSM-promotion-experimentation>
2. NYC Taxi & Limousine Commission, Trip Record Data: <https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page>
3. Active pipeline source: `src/pipeline/main_pipeline.py`
4. Active policy engine: `src/pipeline/policy_comparison_engine.py`
5. Active dashboard: `src/dashboard/app.py`
6. Active configuration: `config.json`
7. Current processed dataset: `data/processed/segmented_simulation_data.csv`

Kết thúc Tài liệu kỹ thuật - Bản cuối